

Algoritmos Genéticos

Mayenka Fernández Chambi

Introducción

- Denominados inicialmente **planes reproductivos genéticos**. [Holland, 1962] observó que usando **reglas simples** se llegaba a comportamientos **adaptativos**, posibilitando estudiar la **evolución de los sistemas complejos**.
- Considerando los siguientes principios:
 1. La adaptación ocurre en **un ambiente**
 2. La adaptación es un **proceso poblacional**
 3. Comportamientos individuales pueden representarse **como programas**
 4. Pueden generarse **comportamientos futuros** haciendo **variaciones aleatorias** en los programas.
 5. Las **salidas de los programas** mantienen relación, si sus respectivas estructuras también la mantienen.

Definición

- Los Algoritmos Genéticos son **algoritmos estocásticos** que implementan **métodos de búsqueda** a partir de un modelo computacional de algunos fenómenos Neodarwinianos como: la herencia genética y la supervivencia de los más aptos.

La metáfora que está detrás de los algoritmos genéticos es la **evolución natural**.

Un sistema **estocástico** es aquel que funciona mayormente por **azar**. Se trata pues de un **algoritmo** matemático que trata los procesos cuya evolución es aleatoria y **que basa su resultado en probabilidades que cambian con el tiempo**.

Componentes de un Algoritmo Genético

- (Michalewics, 1996) afirma que para poder aplicar el algoritmo genético se requiere de los siguientes componentes:
 - a. Una **representación** de las soluciones potenciales del problema, de naturaleza genotípica, denominada **cromosoma**.
 - b. Una forma de **crear una población inicial** de posibles soluciones, que se suele basar en un proceso **aleatorio**.
 - c. Una **función de aptitud** que hace el papel del ambiente.
 - d. **Operadores genéticos** que alteren la composición de los cromosomas seleccionados.
 - e. **Parametrizaciones**, para los diferentes parámetros que utiliza el algoritmo genético: tamaño de la población, probabilidad de aplicar *crossover*, mutación, número máximo de generaciones, etc.

Algoritmo Genético Canónico

- (Golberg, 1989) introdujo el modelo de AG con individuos compuestos por **cadenas de números binarios** $b_i \in \{0,1\}$ para tratar problemas de optimización numérica.
 - i. En este modelo se aprecia el concepto de **genotipo** que es cada una de las cadenas binarias $g_i \equiv b_i$ que codifican a una respectiva solución o **fenotipo** x_i .
 - ii. Aunque una codificación de fenotipo a genotipo $\gamma^{-1}: X \rightarrow G$ no está limitada a la representación binaria en $\{0,1\}$, esta codificación es **muy parecida a los cromosomas biológicos**.

1	1	0	1	0	0	1	1	0	1	0	1	0	0	0	1	0	0	0	1
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---


Procedimiento Genético Elemental

- El pseudocódigo para un algoritmo básico es el siguiente:

Procedimiento Elemental:

```
 $t = 0$   
inicializar población de genotipos  $G_{t=0}$   
decodificar  $G \rightarrow X$  y calcular  $f(x)$   
mientras  $c_{fin} = \text{falso}$  hacer  
    seleccionar  $G_{t+1}$  de  $G_t$   
    operar  $G_{t+1}$ , formando  $G_{t+1}$   
    decodificar y evaluar  $G_{t+1}$   
     $t = t + 1$   
fin mientras
```

Ciclo de un Algoritmo Genético



Representación

- Una representación es fundamental al modelar un algoritmo genético y debe cumplir algunas características como:
 - a. Describir adecuadamente el espacio de búsqueda relevante al problema
 - b. Codificar genéticamente la esencia del problema
 - a. Se evoluciona el código (genótipo) → se evoluciona la solución (fenótipo)
 - c. Ser compatible con los operadores de cruce y mutación


Una representación adecuada contribuirá en el éxito del algoritmo evolutivo.

Representación

- De acuerdo al método de solución se tiene algunas representaciones a ser usadas:


Método de solución	Representación (cromosoma)
Numérica	Binaria, real
Orden	Listas
Grupos	Vectores
Enteros	Entero
Mixto	Combinada (por ejemplo: real y listas)

- El cromosoma **codifica una solución al problema**. Se tendrán tantos genes como parámetros. Dada la función a optimizar $f(x) = f(x_1, x_2)$



Codificación Binaria

- Implica usar el **alfabeto binario** $\mathbb{B} = \{0, 1\}$ obteniendo una **cadena binaria de longitud l** que pertenece a un espacio $\mathbb{B}^l = \mathbb{B} \times \cdots \times \mathbb{B} = \{0, 1\}^l$,
- Sea una función a optimizar $f(x)$, donde $x = \{x_1, \dots, x_n\}$
 - a. Cada variable x_i debe codificarse a una **cadena binaria de longitud l_i** , usando la codificación $\gamma_i^{-1}: \mathbb{Q}_i \mapsto \mathbb{B}^{l_i}$
 - b. El cromosoma total tendrá una longitud $\sum_{i=1}^n l_i$



Se representa hasta 2^l **puntos de búsqueda** diferentes $g_i \in \mathbb{G}$

Codificación de Real a Binario

- Sea la función $f(x)$, $x = \{x_i, \dots, x_n\} \in \mathbb{X} \subseteq \mathbb{R}^n$, a ser optimizada, se requiere codificarla cumpliendo las siguientes propiedades:
 - a. Cada individuo $x = \{x_i, \dots, x_n\} \in \mathbb{X}$ debe codificarse a una **palabra binaria de longitud l** . Para esto se define una función de codificación:


$$\gamma^{-1} : \mathbb{X} \mapsto \mathbb{B}^l \quad (1)$$

- b. Cada variable x_i tiene dominio $x_i \in \langle \text{left}_i, \text{right}_i \rangle$, $\forall_i = (1, \dots, n)$, por lo tanto, debe existir una **función de codificación γ_i^{-1} por cada variable x_i** :

$$\gamma_i^{-1} : \langle \text{left}_i, \text{right}_i \rangle \subset \mathbb{R} \mapsto \mathbb{B}^{l_i} \quad (2)$$

Codificación de Real a Binario

- Si se especifica una **precisión de p_i dígitos decimales** para cada x_i , el espacio $\mathbb{B}^{l_i}$ deberá ser capaz de codificar al menos **$(left_i, right_i) \times 10^{p_i}$** valores para x_i .



- El valor $l_i \in \mathbb{N}$ queda definido por la ecuación:

$$\begin{aligned} 2^{l_i} &\geq (right_i - left_i) \times 10^{p_i} \\ l_i &\geq \log_2(right_i - left_i) + p_i \log_2(10) \end{aligned} \tag{3}$$

Decodificación de Binario a Real

- Se define la decodificación γ_i de **binario a real** para una variable x_i como:

$$\gamma_i : \mathbb{B}^{l_i} \mapsto \langle \text{left}_i, \text{right}_i \rangle \subset \mathbb{R} \quad (4)$$

- Consiste en **convertir la cadena binaria** b_i a decimal y **escalarla** al intervalo de dominio $\langle \text{left}_i, \text{right}_i \rangle$ de acuerdo a la ecuación 5:

$$x_{i(\text{real})} = \text{left}_i + \left(\sum_{j=0}^{l_i-1} 2^j a_j \right) \frac{\text{right}_i - \text{left}_i}{2^{l_i} - 1} \quad (5)$$

- Si una variable $\text{left}_i \leq x_i \leq \text{right}_i$ es codificada en binario, la cadena binaria $b_{inf} = (00 \dots 0)$ **representa el valor left_i** y la cadena binaria $b_{sup} = (11 \dots 1)$ **representa el valor right_i**

Ventajas y Desventajas de la codificación binaria

- **Ventajas:**

- a. La codificación binaria $\gamma: \mathbb{X} \mapsto \mathbb{B}^l$ es simple y fácil de manipular, da buenos resultados y **facilita la acción de los operadores genéticos.**
- b. Se puede codificar diversos tipos de espacios a binarios:
($\mathbb{Z} \mapsto \mathbb{B}^l, \mathbb{R} \mapsto \mathbb{B}^l$, etc.)

- **Desventajas:**

- a. Distancia de Hamming
- b. Incremento de Dimensiones

Se denomina **distancia de Hamming** a la efectividad de los códigos de bloque y depende de la diferencia entre una palabra de código válida y otra.

Desventajas de Codificación Binaria

- **Distancia de Hamming:** Poca coherencia de distancia en bits entre b_i, b_j y las variables x_i, x_j . Se puede mitigar usando el Código de Gray.
- $b \in \mathbb{B}^l$, se codifica a $a = \{a_1, \dots, a_l\} \in \mathbb{B}^l$ en gray usando $\gamma^{-1}: \mathbb{B}^l \mapsto \mathbb{B}_{gray}^l$ definido por 6, donde $\oplus$ es el operador or exclusivo:

$$a_i = \begin{cases} b_i & \text{si } i = 1 \\ b_{i-1} \oplus b_i & \text{en otro caso} \end{cases} \quad (6)$$


- La decodificación consiste en:

$$b_i = \bigoplus_{j=1}^i a_j \quad \forall i = \{1, \dots, l\} \quad (7)$$


Decimal	Binario	Gray
0	000	000
1	001	001
2	010	011
3	011	010
4	100	110
5	101	111
6	110	101
7	111	100

Desventajas de Codificación Binaria

- **Incremento de la Dimensión:** En una codificación $\gamma^{-1}: \mathbb{R}^n \mapsto \mathbb{B}^l$ siempre ocurre que $l \gg n$ por defecto de la discretización y la **baja cardinalidad** del espacio resultante:



Ciclo de un Algoritmo Genético



Inicialización de la Población X_0

- I. Sea la población $X = \{x_i\}_{i=1}^m$, donde $x = \{x_1, \dots, x_n\}$
- II. Se inicializa cada variable $x_j \in \langle \text{left}_j, \text{right}_j \rangle, j = 1, \dots, n$ de cada individuo $x_i \in X_0, i = 1, \dots, m$ conforme:

$$x_j = \text{left}_j + (\text{right}_j - \text{left}_j)U(t) \quad (8)$$

Donde $U(t)$ es un generador de números aleatorios (0,1)

Si se está empleando una codificación $\gamma^{-1} : \mathbb{R}^n \mapsto \mathbb{B}^l$, entonces:

- Inicializar generando *bits* aleatorios 0 ó 1 y colocarlos en las cadenas $\mathbf{b}_i$
- La precisión y dominios están garantizados por la codificación $\gamma^{-1} : \mathbb{R}^n \mapsto \mathbb{B}^l$

Aptitud: Evaluación vs Aptitud

- **Función de Evaluación:**
- La función de evaluación $f(x)$ es el **enlace entre el algoritmo genético y el problema en cuestión**. Se puede definir como el resultado de aplicar en el problema a ser optimizado, los valores del individuo $x = \{x_1, \dots, x_n\}$.
 - $f(x) = \text{evaluación de } x_i$

Aptitud:

La aptitud **a** es el **valor numérico** que se le asigna a cada individuo (fenotipo) x_i indicando **qué tan bueno** es con respecto a los demás individuos de la población X para la solución del problema.

$$a(f(x), X) = \text{aptitud de } x_i$$

Ejemplo: Optimización de F6


Sea la función $F_6(x_1, x_2)$ definida por:

$$F_6(x_1, x_2) = 0.5 - \frac{\left(\sin \sqrt{x_1^2 + x_2^2}\right)^2 - 0.5}{(1.0 + 0.001(x_1^2 + x_2^2))^2} \quad (9)$$

que tiene muchos **máximos y mínimos locales**, y un óptimo global $\mathbf{x}^* = (0, 0)$ tal que $f(\mathbf{x}^*) = f(0, 0) = 1.00$.

- Se desea optimizar esta función considerando los siguientes dominios:
- $x_1 \in \langle -100, 100 \rangle$
- $x_2 \in \langle -100, 100 \rangle$

Ejemplo: Gráfica



Ejemplo: Definir cromosoma e inicializarlo

- Se desea **codificar a binario** ($\gamma^{-1}: \mathbb{X} \mapsto \mathbb{B}^l$) **con una precisión de 4 a 5 cifras decimales** por cada variable x_i . Se calcula $l_i \in \mathbb{N}$ usando la ecuación 3 de la siguiente manera:


$$\begin{aligned}\log_2((100 - (-100) \times 10^4) \leq l_i \leq \log_2((100 - (-100) \times 10^5) \\ \log_2(2 \times 10^6) \leq l_i \leq \log_2(2 \times 10^7) \\ 20.93 \leq l_i \leq 24.25\end{aligned}$$

- Donde $l_i = 21, 22, 23, 24$, seleccionamos $l_i = 22$. El cromosoma tendrá una longitud total igual a $l_i + l_i = 44$ *bits*


La inicialización de $\mathbf{X}_0$ consistirá simplemente en el **llenado de bits $\{0, 1\}$ aleatorios** en cada cromosoma binario $\mathbf{b}_i$.

Ejemplo: Evaluación

Es necesario aplicar decodificación $\gamma : \mathbb{G} \mapsto \mathbb{X}$ para poder evaluarlos.



Ciclo de un algoritmo genético



Selección

- Dada una población inicial $X_0 = \{x_i\}_{i=1}^m$ y sus aptitudes $A_t = a(X_0)$, se seleccionan los individuos a reproducirse de acuerdo a su aptitud, que se comporta como una probabilidad de selección.

En algoritmos genéticos hay 2 tipos de selección:

- I. **Selección proporcional:** los individuos se seleccionan de acuerdo a su **contribución de aptitud** con respecto al total de aptitud de la población.
- II. **Selección mediante torneo:** propuesta por (Wetzel, 1983), tiene como idea básica seleccionar individuos **comparando directamente sus aptitudes**.

Selección Proporcional

- Dentro de este grupo, se tiene las siguientes estrategias:

I. Selección por Ruleta

II. Sobrante Estocástico

III. Universal Estocástico

IV. Muestreo Determinístico

Adicionalmente existen otras técnicas que implementan los siguientes aditamentos:

i. Escalamiento- σ

ii. Uso de jerarquías

iii. Selección de Boltzman

Selección por Ruleta

- Es la estrategia más utilizada por su simplicidad y facilidad de entendimiento. Su algoritmo es:

Requiere: $\mathbf{X}_t$ (población), $\mathcal{A}_t$ (vector de aptitudes)
calcular $\mathcal{B}_t = \{b_1, \dots, b_m\}$ (aptitudes acumuladas)

$$\begin{aligned} b_i &= a_i & i &= 1 \\ b_i &= b_{i-1} + a_i & i &> 1 \end{aligned}$$

$j = 0$

generar $u_j = b_m \mathbf{U}(0, 1)$

mientras $u_j \notin [x_j, x_{j+1}]$ **hacer**

$j = j + 1$

fin mientras

seleccionar $\mathbf{x}_j \in \mathbf{X}_t$

Selección por Ruleta

- Dado un individuo x_i y su aptitud $a(x_i, X_t)$, su probabilidad de selección p_x , por ruleta será:

$$p_{x_i} = \frac{a(x_i, X_t)}{\sum_{k=1}^m a_k} \quad (10)$$

- Análisis:
 - i. Complejidad computacional $O(n^2)$
 - ii. Sujeta al error de muestreo, no siempre se cumple el valor esperado $E_s[x_i]$ de selección
 - iii. Se puede usar búsqueda binaria reduciendo la complejidad total a $O(n \log n)$

Selección por Ruleta

- **Ejemplo:**

Sea la población $\mathbf{X}_t = \{\mathbf{x}_i\}_1^6$ de la siguiente tabla:

Individuo i	genotipo	$a_i \in \mathcal{A}_t$	$b_i \in \mathcal{B}_t$	$a_i/b_m(\%)$
$\mathbf{x}_1$	11010110	254	254	24.49%
$\mathbf{x}_2$	10100111	47	301	4.53%
$\mathbf{x}_3$	00110110	457	758	44.07%
$\mathbf{x}_4$	01110010	194	952	18.71%
$\mathbf{x}_5$	11110010	85	1037	8.20%
Total		1037		100.00%

Sobranate Estocástico

- Es una alternativa que busca una **mejor aproximación del valor esperado de selección** $E_s[x_i]$ definido por la ecuación 11:

$$E_s[x_i] = m \frac{a(f(\mathbf{x}_i), \mathbf{X}_t)}{b_m} \quad (11)$$

- Consiste en:
 1. Asignar en **forma determinística** el conteo de los valores esperados, es decir, la parte entera $e_t = m(a_i/b_m)$ para después.
 2. **Completar** los individuos faltantes por el redondeo mediante un **esquema probabilístico y proporcional** (por ejemplo una ruleta)

Sobranate Estocástico

- **Ejemplo:**

Se ilustra un ejemplo del uso del sobranate estocástico

Individuo i	genotipo	$a_i \in \mathcal{A}_t$	e_t	$\text{int}(e_t)$	$e_t - \text{int}(e_t)$
x_1	110100	220	1.23	1	0.23
x_2	011010	140	0.78	0	0.78
x_3	111001	315	1.76	1	0.76
x_4	001101	42	0.23	0	0.23
Total		717	4.00	2	

Con esta metodología, **se reducen los problemas de muestreo** de la ruleta, aunque se puede causar convergencia prematura debido a la mayor presión selectiva.

Selección por Torneo

- Propuesta por (Wetzel, 1983), tiene como idea básica seleccionar individuos **comparando directamente sus aptitudes**.

Requiere: $X_t, \mathcal{A}_t$
desordenar X_t
escoger k individuos (comúnmente $k = 2$)
comparar los k individuos por su aptitud $a(\cdot)$
seleccionar el individuo con mejor aptitud

- La selección por Torneo es bastante **simple y determinista** con **características extintiva**.
- Hay una versión **probabilística** que elimina la característica extintiva, ya que, en algunas ocasiones, elementos menos aptos pueden ganar el torneo y ser seleccionados.

Selección por Torneo

- **Análisis:**

- i. La versión determinista garantiza selección del mejor individuo.
- ii. En un torneo, siempre se escogen k individuos, por lo tanto la complejidad es $O(1)$
- iii. Se requieren m competencias de k individuos para escoger una nueva población por una generación, por lo tanto la complejidad es $O(m)$
- iv. La técnica es eficiente y fácil de implementar
- v. No requiere **escalar la función de aptitud**, las comparaciones se hacen directamente
- vi. En la versión determinista, se puede introducir una **presión selectiva fuerte**; individuos menos aptos no sobreviven
- vii. Se puede regular la presión selectiva variando la cantidad k de individuos que compiten

Selección de Boltzman

- i. Basada en la heurística de Simulated Annealing – variación de la temperatura:
 - i. Temperatura “alta” al inicio (menor presión selectiva)
 - ii. Temperatura “baja” al final (más presión selectiva)
- ii. Se calcula el valor esperado de cada individuo típicamente usando:

$$E[i, t] = \frac{e^{f(i)/T}}{\langle e^{f(i)/T} \rangle^t} \quad (12)$$

Donde T es la temperatura y $\langle . \rangle^t$ es el promedio de las aptitudes de la población


Una vez calculados los valores esperados, se hace la selección mediante una ruleta

Operadores Genéticos

- **Manipulan el genotipo**, influyen en la transmisión de la información genética de padres a hijos. Los operadores tienen dos categorías principales:
 - I. **Cruces** (Cruzamiento o Crossover): que forman dos nuevos individuos a partir de la **recombinación de información** de los dos individuos seleccionados para operar. Los más conocidos son:
 - I. Cruce de un punto
 - II. Cruce de dos puntos
 - III. Cruce uniforme
 - II. **Mutaciones**: que forman un nuevo individuo a partir de las **alteraciones en los genes** de un único individuo seleccionado, la más conocida es la mutación de *bit*.

Cruce de un punto


- A partir de un **par de genotipos** seleccionados g_1 y g_2 y un **punto de corte aleatorio**, se generan dos descendientes g'_1 y g'_2 como ilustra la figura




Cruce de dos puntos

- En este caso, se usan **dos puntos de corte**, generados aleatoriamente. Se obtiene **un segmento** de los cromosomas *padres* g_1 y g_2 que se intercambiará conforme ilustra la figura.

Antes del cruce



Después del cruce



Cruce uniforme

- Este operador **recorre** los cromosomas escogidos g_1 y g_2 y mediante un sorteo $U(t)$, determina cuál gen g_{1i} y g_{2i} formará los genes de los descendientes g'_1 y g'_2

Antes del cruce


g_1	0	1	0	0	0	1	0	1
g_2	1	1	1	1	1	0	1	1
	$U(t)_1 \geq 0.5$	$U(t)_2 \geq 0.5$	$U(t)_3 < 0.5$	$U(t)_4 \geq 0.5$	$U(t)_5 < 0.5$	$U(t)_6 < 0.5$	$U(t)_7 \geq 0.5$	$U(t)_8 < 0.5$

Después del cruce

g'_1	0	1	1	0	1	0	0	1
g'_2	1	1	0	1	0	1	1	1

Mutación

- Escoge algún gen $g_i \in g$ y lo altera a otro valor. Tratándose de un individuo con **genotipo binario**, un gen sería un *bit* y su alteración es de valor 1 a valor 0 o viceversa.



Dilema Exploiting - Exploring

- En los sistemas de aprendizaje se desea aprovechar los **conocimientos existentes (Exploiting)** y también buscar **nuevo conocimiento (Exploring)**. Los algoritmos evolutivos no son ajenos a esta situación.
 - i. **Exploiting:** aprovechar la información que la población actual X_t tiene sobre el espacio de búsqueda.
 - ii. **Exploring:** ir a regiones del espacio de búsqueda no visitadas antes, no quedarse en óptimos locales.

Los **cruces** proveen la característica **Exploiting**

Las **mutaciones** proveen la característica **Exploring**

La parametrización adecuada de las características **exploiting – exploring** será dado mediante **el ajuste de las probabilidades** de uso de los operadores genéticos.

Ajustes en la Aptitud

- Durante el cálculo de la aptitud de la población, se puede encontrar los dos siguientes problemas:
 - Poca precisión selectiva:** Aptitudes con valores similares, haciendo la selección muy próxima a la búsqueda aleatoria
 - Súperindividuo:** algunos individuos con aptitud muy alta con respecto a los demás. La selección escoge sólo estos individuos, perdiendo diversidad genética y ocurriendo convergencia prematura.

Para tratar estos efectos se realiza ajustes en las aptitudes:

- Aptitud = Evaluación
- Windowing
- Normalización Lineal

Ajustes en la Aptitud

Aptitud = evaluación:

Cuando **no hay necesidad de ajustes** en la función de evaluación $f(\mathbf{x}_i)$ para obtener la aptitud, entonces:

$$a(f(\mathbf{x}_i), \mathbf{X}_t) = f(\mathbf{x}_i) \quad (13)$$

Windowing:

Cuando existe **competición próxima**, se puede ajustar la aptitud usando la siguiente expresión:

$$a(f(\mathbf{x}_i), \mathbf{X}_t) = f(\mathbf{x}_i) - f_{min}(\mathbf{X}_t) + a_{min} \quad (14)$$

donde $f_{min}(\mathbf{X}_t)$ es la evaluación **mínima** hallada en la población $\mathbf{X}_t$, y a_{min} (opcional) es una **aptitud mínima de sobrevivencia** para garantizar la reproducción de los cromosomas menos aptos.

Ajustes en la Aptitud

- **Normalización Lineal**
- Sea una población X_t con m individuos **ordenados por las evaluaciones $\mathcal{F}_t$** . **La idea es ajustar la aptitud** desde un v_{min} hasta un v_{max} con pasos fijos como se indica en el algoritmo:

```
Requiere:  $X_t, \mathcal{F}_t$   
Requiere:  $v_{min}, v_{max}$   
ordenar  $X_t$  decrecientemente según  $\mathcal{F}_t$   
 $i = 0$   
mientras  $i < m$  hacer  
  crear  $\mathcal{A}_t = \{a_i\}_{i=1}^m$  usando:  
    
$$a_i = v_{min} + \frac{(v_{max} - v_{min})}{m - 1}(i - 1)$$
  
   $i = i + 1$   
fin mientras
```

Ajustes en la selección

- Se debe tratar la **brecha generacional** que se refiere a la transición de individuos de la población X_t a la población X_{t+1} .
- **Elitismo:**
- Consiste en tener una **copia del mejor individuo** $x_{best} \in X_t$ para colocarlo en la población X_{t+1} después del proceso de evolución (selección, reproducción, evaluación).
 - i. Se reduce el efecto aleatorio del proceso evolutivo
 - ii. Se garantiza que el mejor individuo $x_{best} \in X_{t+1}$ será siempre mejor o igual a $x_{best} \in X_t$
 - iii. Se prueba que el Elitismo es condición necesaria para la convergencia al óptimo.

Ajustes en la Selección

- **Steady – state**
- Existe un **reemplazo parcial** de los individuos de X_t al generar X_{t+1} . La metodología de realización de Steady state es la siguiente:

seleccionar $k < m$ individuos de X_t
operar estos k individuos (cruces, mutacion)
eliminar los k peores elementos de X_t
obtener X_{t+1} insertando los n individuos generados

- Donde k es la fracción de individuos a reemplazarse, $k < m$, y se define $k = GAP \times m$

Ejemplo

- Ajuste de selección:

Steady-state - funcionamiento

x_{16}	99
x_{15}	95
x_{14}	81
x_{13}	76
x_{12}	67
x_{11}	58
x_{10}	44
x_{09}	42
x_{08}	36
x_{07}	22
x_{06}	20
x_{05}	19
x_{04}	17
x_{03}	10
x_{02}	8
x_{01}	5

Población X_t y
evaluaciones $f(x_i)$

38
6
121
88
58
17

k nuevos
individuos



99
95
81
76
67
58
44
42
36
22
38
6
121
88
58
17

reemplazar los
 k peores

121
99
95
88
81
76
67
58
58
44
42
38
36
22
17
6

Población X_{t+1} y
evaluaciones $f(x_i)$

Ajustes en la selección

- **Steady-state sin repetidos**
- Reemplazo parcial de la población **excluyendo los individuos repetidos**:
 - i. **Evita individuos repetidos** que son más frecuentes en poblaciones con Steady-state que son más estáticas.
 - ii. Aumenta la eficiencia del **paralelismo de búsqueda**, dado que se aumenta la diversidad.

Dado un individuo repetido:

- i. Se genera un nuevo individuo aleatoriamente verificando que no sea repetido,
ó
 - ii. Se opera el individuo (cruzar o mutar) hasta obtener un individuo diferente
- Este método aumenta el costo computacional.

Monitoreo del algoritmo genético

- Para verificar el **comportamiento de una población X** durante las generaciones, se emplean **curvas de desempeño** de las ejecuciones de un algoritmo que son los siguientes tipos:
 - i. Curva *best-so-far*
 - ii. Curva *online*
 - iii. Curva *offline*

Curva *best-so-far*:

Observa los valores $\mathbf{x}_{best}(t)$ durante las generaciones 1 a t :

$$v_{best}(t) = f(\mathbf{x}_{best}, t) \quad (15)$$

donde $f(\mathbf{x}_{best}, t)$ es la evaluación **del mejor elemento** de la generación t .

Monitoreo del algoritmo genético

Curva *online*:

- Visualiza la rápida obtención de buenas soluciones y la convergencia de la población.
- Cada punto de la curva es dado por :

$$v_{on}(t) = \frac{1}{t+1} \sum_{i=0}^t \bar{f}(\mathbf{X}_t) \quad (16)$$

donde $\bar{f}(\mathbf{X}_t)$ es la media de las evaluaciones de todos los individuos $\mathbf{x}_i \in \mathbf{X}_t$, para la generación t ($t = 0$ es la población inicial).

Monitoreo del algoritmo genético

Curva *off-line*:


- Visualiza la obtención de buenas soluciones sin importar el tiempo tomado para encontrarlas.
- Cada punto de la curva es dado por:

$$v_{off}(t) = \frac{1}{t+1} \sum_{i=0}^t f(\mathbf{x}_{best}, t) \quad (17)$$

donde $f(\mathbf{x}_{best}, t)$ es la evaluación del mejor elemento de la generación t , ($t = 0$ es la población inicial).

- Son necesarias muchas ejecuciones y curvas online, offline medias para tener una mejor visualización del comportamiento de un algoritmo genético.

Monitoreo de un algoritmo genético



Bibliografía

- Tupac, Y. (2015). Computación Evolutiva: Algoritmos Genéticos, ppt.
- Goldberg, D. E. (1989). Genetic algorithms in search. *Optimization, and MachineLearning*.
- Holland, J. H. (1962). Outline for a logical theory of adaptive systems. *Journal of the ACM (JACM)*, 9(3), 297-314.
- Michalewicz, Z. (2013). *Genetic algorithms+ data structures= evolution programs*. Springer Science & Business Media.
- Rudolph, G. (1994). Convergence analysis of canonical genetic algorithms. *IEEE transactions on neural networks*, 5(1), 96-101.
- Wetzel, A. (1983). Evaluation of the effectiveness of genetic algorithms in combinatorial optimization. *University of Pittsburgh*, 1, 983.

Ejemplos:

- https://github.com/danielTeniente/ia-projects/blob/main/Algoritmos_geneticos/Maximizar_funcion.ipynb